

LAPORAN

PENERAPAN ALGORITMA APRIORI DALAM ANALISIS POLA PEMBELIAN KONSUMEN MENGGUNAKAN DATASET MARKET BASKET OPTIMISATION



Oleh:

**JUWITA SARA SAFITRI
24260006**

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNIK DAN ILMU KOMPUTER
UNIVERSITAS NAHDLATUL ULAMA INDONESIA
BOGOR
2026**

KATA PENGANTAR

Puji dan syukur penulis panjatkan kehadiran Allah SWT atas segala rahmat, taufik, dan hidayah-Nya sehingga penulis dapat menyelesaikan laporan Ujian Akhir Semester (UAS) Mata Kuliah Machine Learning yang berjudul "Penerapan Algoritma Apriori dalam Analisis Pola Pembelian Konsumen Menggunakan Dataset Market Basket Optimisation" ini dengan baik dan tepat waktu.

Laporan ini disusun sebagai salah satu syarat pemenuhan tugas UAS pada Program Studi Teknik Informatika, Fakultas Teknik dan Ilmu Komputer, Universitas Nahdlatul Ulama Indonesia (UNUSIA) Bogor. Dalam laporan ini dibahas implementasi algoritma Apriori secara manual menggunakan bahasa pemrograman Python untuk menemukan pola pembelian konsumen melalui pendekatan Association Rule Mining pada dataset Market Basket Optimisation yang berisi 7.501 transaksi.

Penulis menyadari bahwa dalam penyusunan laporan ini masih terdapat berbagai kekurangan. Oleh karena itu, penulis dengan terbuka menerima segala kritik dan saran yang bersifat membangun demi perbaikan dan penyempurnaan laporan ini di masa mendatang.

Pada kesempatan ini penulis ingin menyampaikan ucapan terima kasih yang sebesar-besarnya kepada semua pihak yang tidak dapat penulis sebutkan satu per satu, yang telah turut berkontribusi dalam penyelesaian laporan ini.

Akhir kata, penulis berharap laporan ini dapat memberikan manfaat dan menambah wawasan bagi pembaca, khususnya mengenai penerapan algoritma Apriori dalam bidang data mining dan machine learning.

Bogor, 30 Juni 2026

Juwita Sara Safitri
NIM. 24260006

DAFTAR ISI

KATA PENGANTAR	i
DAFTAR ISI	ii
DAFTAR TABEL	iii
DAFTAR GAMBAR	iv
DAFTAR RUMUS	v
BAB 1 PENDAHULUAN	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah	2
1.3. Batasan Masalah	2
1.4. Tujuan Penelitian	3
1.5. Manfaat Penelitian	3
1.6. Metode Penelitian	3
1.7. Sistematika Penulisan	4
BAB 2 TINJAUAN PUSTAKA	5
2.1. Penelitian Terdahulu	5
2.2. Landasan Teori	7
2.2.1. Data Mining	7
2.2.2. Knowledge Discovery in Database (KDD)	7
2.2.3. Association Rule	8
2.2.4. Market Basket Analysis	8
2.2.5. Algoritma Apriori	10
2.2.6. One-Hot Encoding	12
2.2.7. Support	13
2.2.8. Confidence	13
2.2.9. Lift Ratio	13
2.2.10. Dataset Market Basket Optimisation	14
2.2.11. Python	14
2.2.12. Pandas	15
BAB 3 METODOLOGI PENELITIAN	16
3.1. Kerangka Berpikir	16
3.2. Pengumpulan dan Pengolahan Data	17
3.2.1. Pengumpulan Data	17
3.2.2. Pengolahan Data	18
3.3. Perancangan Teknik/Model (Kebaharuan)	20
3.4. Evaluasi Teknik/Model (Teknik Evaluasi)	21
BAB 4 IMPLEMENTASI DAN EKSPERIMEN	23
4.1. Persiapan Data	23
4.1.1. Pengumpulan Data	23
4.1.2. Pengolahan Data	23
4.2. Implementasi Teknik/Model	24

4.2.1. Implementasi Algoritma Apriori Manual -----	24
4.2.2. Implementasi Pembentukan Association Rules -----	26
4.3. Hasil dan Analisis-----	27
4.3.1. Interpretasi Kinerja Model-----	27
4.3.2. Evaluasi Kinerja Model -----	28
4.3.3. Pembahasan Temuan -----	29
4.3.4. Hasil -----	29
BAB 5 PENUTUP -----	31
5.1. Kesimpulan -----	31
5.2. Saran-----	31
DAFTAR PUSTAKA-----	33

DAFTAR TABEL

Tabel 2.1. Penelitian Terdahulu -----	6
Tabel 3.1. Kerangka Berpikir (Input – Proses – Output)-----	16
Tabel 3.4. Parameter Evaluasi: min_support, min_confidence, dan Interpretasi Lift-----	21
Tabel 4.2.1. Hasil Implementasi Algoritma Apriori per Level-----	25
Tabel 4.3.1. 15 Frequent Itemsets dengan Nilai Support Tertinggi-----	27
Tabel 4.3.2. 10 Association Rules dengan Nilai Lift Tertinggi -----	28
Tabel 4.3.3. Evaluasi Kinerja Model: Apriori Manual vs Brute Force-----	28

DAFTAR GAMBAR

Gambar 3.2.1. Flowchart Pengumpulan Data -----	18
Gambar 3.2.2. Flowchart Pengolahan Data-----	19
Gambar 4.3.4. Hasil Implementasi (Top 10 Produk, Top 10 Frequent Itemsets, -----	30
Scatter Plot Support–Confidence–Lift, Top 10 Rules Berdasarkan Lift)	

DAFTAR RUMUS

Rumus 2.1. $\text{Support}(A) = \text{Jumlah transaksi yang memuat } A / \text{Total transaksi}$ -----	13
Rumus 2.2. $\text{Confidence}(A \rightarrow B) = \text{Support}(A \cup B) / \text{Support}(A)$ -----	13
Rumus 2.3. $\text{Lift}(A \rightarrow B) = \text{Confidence}(A \rightarrow B) / \text{Support}(B)$ -----	13
Rumus 4.1. $C(53,2) = (53 \times 52) / 2 = 1.378$ (Verifikasi join step level 2) -----	26
Rumus 4.2. $C(120,2) = 7.140$ (Brute force level 2)-----	28
Rumus 4.3. $C(120,3) = 280.840$ (Brute force level 3)-----	28

BAB 1

PENDAHULUAN

1.1. Latar Belakang

Perkembangan teknologi informasi telah mendorong pertumbuhan volume data transaksi penjualan secara signifikan, baik pada ritel konvensional maupun platform e-commerce. Berdasarkan data resmi Badan Pusat Statistik, nilai transaksi e-commerce nasional terus menunjukkan tren peningkatan dalam beberapa tahun terakhir, didorong oleh perubahan kebiasaan belanja masyarakat, kemajuan sistem pembayaran digital, serta ekspansi platform social commerce (Pravitasari & Sutarsih, 2025). Pertumbuhan nilai transaksi yang pesat ini secara langsung berarti pertumbuhan volume data transaksi yang harus dikelola oleh pelaku usaha, baik secara daring maupun melalui sistem kasir ritel konvensional.

Setiap transaksi pembelian yang dilakukan oleh pelanggan menghasilkan data yang, jika dikumpulkan dalam jumlah besar, menyimpan informasi berharga mengenai kebiasaan dan preferensi konsumen dalam berbelanja. Data transaksi semacam ini pada dasarnya merekam hubungan antar produk yang dibeli secara bersamaan oleh pelanggan, dan hubungan inilah yang menjadi dasar bagi algoritma Apriori untuk menemukan aturan asosiasi (association rules) serta frequent itemset dari basis data transaksi berskala besar (Nurhidayanti & Kurniawati, 2022). Hubungan semacam ini tidak dapat ditemukan hanya dengan melihat data transaksi secara manual, terutama ketika jumlah transaksi dan jenis produk yang terlibat sudah mencapai ribuan hingga jutaan.

Memahami pola pembelian pelanggan menjadi hal yang penting bagi pelaku usaha ritel, karena informasi tersebut dapat dimanfaatkan untuk berbagai keputusan bisnis, seperti penataan letak produk, strategi bundling, dan perancangan promosi yang lebih tepat sasaran (Purwati & Karnila, 2023a). Sebagai contoh, apabila diketahui bahwa pelanggan yang membeli produk A juga cenderung membeli produk B, maka pelaku usaha dapat menempatkan kedua produk tersebut berdekatan di rak penjualan, menawarkan paket bundling keduanya, atau memberikan rekomendasi produk B kepada pelanggan yang sedang membeli produk A pada platform e-commerce.

Tanpa analisis yang tepat, data transaksi yang besar hanya akan menjadi kumpulan data mentah tanpa nilai tambah bagi pengambilan keputusan, karena Data Mining justru hadir untuk menggali pengetahuan dan pola yang bermanfaat dari kumpulan data berukuran besar yang sebelumnya tidak termanfaatkan secara optimal (Buulolo, 2020). Pelaku usaha yang tidak menganalisis pola pembelian pelanggannya berisiko kehilangan peluang cross-selling, melakukan penataan produk yang kurang optimal, serta kesulitan memprediksi kombinasi produk apa yang sebaiknya distok bersamaan.

Data Mining hadir sebagai solusi untuk mengekstraksi pola dan informasi tersembunyi dari kumpulan data transaksi yang besar. Salah satu teknik dalam Data Mining yang banyak digunakan untuk menganalisis pola pembelian adalah Association Rule Mining, yaitu salah satu metode Data Mining yang dapat mengidentifikasi hubungan keterkaitan antar item, di mana item yang sering dibeli secara bersamaan dalam satu transaksi akan dibentuk menjadi suatu aturan asosiasi (Nurhidayanti & Kurniawati, 2022).

Algoritma Apriori dipilih dalam penelitian ini karena merupakan salah satu algoritma Association Rule Mining yang paling banyak diterapkan dan terbukti efektif dalam

menemukan frequent itemset serta menghasilkan association rules pada berbagai studi kasus transaksi ritel (Febrianto & Supriyanto, 2022; Oktaviani, 2024). Beberapa penelitian sebelumnya juga menunjukkan bahwa algoritma Apriori dapat diterapkan pada berbagai skala data, mulai dari toko kecil hingga data transaksi berskala besar, dengan hasil association rules yang dapat diinterpretasikan secara langsung melalui nilai support, confidence, dan lift (Syafira Rifania et al., 2023).

Dataset yang digunakan dalam penelitian ini adalah Market Basket Optimisation, yaitu dataset publik yang berisi 7.501 transaksi pembelian pelanggan supermarket dengan 20 kolom slot produk per transaksi (d4rklucif3r, n.d.). Dataset ini dipilih karena merupakan salah satu benchmark yang umum digunakan dalam literatur Association Rule Mining, sehingga hasil penelitian ini dapat lebih mudah dibandingkan dengan penelitian-penelitian sejenis.

Berdasarkan uraian tersebut, penelitian ini akan menerapkan algoritma Apriori pada dataset Market Basket Optimisation yang berisi 7.501 transaksi pembelian pelanggan supermarket, untuk menemukan frequent itemset dan association rules yang dapat menggambarkan pola pembelian konsumen secara lebih komprehensif dibandingkan studi kasus skala kecil pada penelitian-penelitian sebelumnya. Sebagai nilai tambah, algoritma Apriori pada penelitian ini diimplementasikan secara manual tanpa pustaka data mining siap pakai, sehingga seluruh proses kerja algoritma dapat dijelaskan dan dibuktikan secara transparan dan kuantitatif.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana mengimplementasikan algoritma Apriori secara manual pada data transaksi Market Basket Optimisation tanpa menggunakan pustaka data mining siap pakai?
2. Bagaimana menentukan frequent itemset dan association rules berdasarkan nilai minimum support dan minimum confidence dari data transaksi tersebut?
3. Pola pembelian apa yang paling sering muncul dan memiliki kekuatan asosiasi tertinggi berdasarkan nilai lift pada hasil association rules?

1.3. Batasan Masalah

Agar penelitian ini lebih terarah, ditetapkan batasan masalah sebagai berikut:

1. Data yang digunakan terbatas pada dataset Market Basket Optimisation dari Kaggle, yang terdiri dari 7.501 transaksi dengan maksimal 20 item per transaksi.
2. Algoritma yang digunakan hanya algoritma Apriori, tanpa membandingkan dengan algoritma association rule lain seperti FP-Growth atau Eclat.
3. Implementasi dilakukan secara manual dari nol (from scratch) menggunakan bahasa pemrograman Python, dengan pustaka pandas hanya untuk manipulasi data. Tidak digunakan pustaka khusus data mining seperti mlxtend.

4. Nilai minimum support ditetapkan sebesar 0,02 (2% dari total transaksi) dan minimum confidence sebesar 0,2 (20%), ditentukan berdasarkan karakteristik dataset.
5. Penelitian ini terbatas pada analisis pola dan evaluasi association rules, tidak mencakup penerapan langsung ke sistem rekomendasi pada platform e-commerce

1.4. Tujuan Penelitian

Tujuan yang ingin dicapai dalam penelitian ini adalah:

1. Mengimplementasikan algoritma Apriori secara manual pada data transaksi Market Basket Optimisation menggunakan Python.
2. Menemukan frequent itemset berdasarkan nilai minimum support yang ditetapkan melalui proses candidate generation, support counting, dan pruning berbasis Apriori Property.
3. Membentuk dan mengevaluasi association rules berdasarkan nilai support, confidence, dan lift ratio untuk mengidentifikasi pola pembelian konsumen yang paling signifikan.

1.5. Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat bagi beberapa pihak:

1. Bagi Penulis: Menambah wawasan dan pemahaman mendalam mengenai cara kerja algoritma Apriori secara internal, tidak sekadar memanggil fungsi dari pustaka siap pakai.
2. Bagi Pelaku Usaha Ritel: Menjadi referensi dalam pengambilan keputusan bisnis seperti penataan produk, strategi bundling, dan promosi berdasarkan pola pembelian konsumen yang ditemukan.
3. Bagi Peneliti Selanjutnya: Menjadi acuan implementasi manual algoritma Apriori yang dapat dikembangkan lebih lanjut atau dibandingkan dengan algoritma association rule lainnya seperti FP-Growth.

1.6. Metode Penelitian

Penelitian ini dilakukan melalui beberapa tahapan. Adapun metode yang digunakan dalam tiap-tiap tahapan antara lain:

1) Metode Pengumpulan Data

Data diperoleh secara sekunder dari dataset publik Market Basket Optimisation yang tersedia di platform Kaggle, dalam format file CSV. Dataset ini berisi 7.501 transaksi pembelian pelanggan supermarket dengan maksimal 20 produk per transaksi..

2) Metode Analisis Data

Dataset diolah menggunakan bahasa pemrograman Python. Pustaka pandas digunakan untuk membaca file CSV dan eksplorasi data awal. Seluruh proses algoritma Apriori termasuk candidate generation, support counting, pruning berbasis Apriori Property,

pembentukan association rules, serta penghitungan nilai confidence dan lift diimplementasikan secara manual menggunakan modul bawaan Python (itertools, collections) tanpa menggunakan pustaka khusus data mining.

3) Metode Pemodelan dan Validasi Data

- a. Menentukan nilai minimum support sebesar 0,02 dan minimum confidence sebesar 0,2 berdasarkan studi literatur dan karakteristik dataset.
- b. Menerapkan algoritma Apriori manual untuk menemukan frequent itemset, kemudian membentuk association rules dari itemset yang ditemukan.
- c. Mengevaluasi association rules menggunakan nilai support, confidence, dan lift ratio. Aturan dengan nilai lift > 1 menunjukkan korelasi positif yang nyata antar item. Kebenaran implementasi manual juga diverifikasi melalui sanity-check langsung terhadap data.

1.7. Sistematika Penulisan

Sistem penulisan dalam tugas akhir ini disusun dalam bentuk karya ilmiah dengan struktur penulisan sebagai berikut:

BAB 1 PENDAHULUAN

Berisi latar belakang, rumusan masalah, batasan masalah, tujuan, manfaat, metode penelitian, dan sistematika penulisan.

BAB 2 TINJAUAN PUSTAKA

Membahas penelitian terdahulu serta landasan teori mengenai Data Mining, Association Rule Mining, dan algoritma Apriori beserta tahapan-tahapannya.

BAB 3 METODOLOGI PENELITIAN

Menjelaskan kerangka berpikir, tahapan pengumpulan dan pengolahan data, rancangan implementasi manual algoritma Apriori, serta teknik evaluasi yang digunakan.

BAB 4 IMPLEMENTASI DAN EKSPERIMEN

Menyajikan hasil implementasi algoritma Apriori manual, frequent itemset yang ditemukan, association rules yang terbentuk, analisis efisiensi algoritma, serta interpretasi hasil.

BAB 5 PENUTUP

Memuat kesimpulan dari hasil penelitian dan saran untuk penelitian selanjutnya.

DAFTAR PUSTAKA

Daftar pustaka berisi daftar referensi yang digunakan dalam penelitian.

BAB 2

TINJAUAN PUSTAKA

2.1. Penelitian Terdahulu

Sebelum melakukan penelitian ini, penulis menelusuri sejumlah penelitian terdahulu yang membahas penerapan algoritma Apriori dan teknik Association Rule Mining pada berbagai konteks data transaksi. Penelusuran ini bertujuan untuk memastikan keaslian penelitian serta menemukan posisi dan kontribusi penelitian ini terhadap penelitian-penelitian yang telah ada sebelumnya.

Penelitian pertama dilakukan oleh Febrianto & Supriyanto (2022) dalam jurnal JURIKOM berjudul "Implementasi Algoritma Apriori Untuk Menentukan Pola Pembelian Produk". Penelitian ini menerapkan algoritma Apriori untuk menemukan pola pembelian produk pada data transaksi penjualan, dengan memanfaatkan pustaka data mining siap pakai untuk menjalankan algoritma tersebut. Pendekatan ini memang efisien dari sisi waktu pengerjaan, namun proses internal algoritma seperti bagaimana kandidat itemset dibentuk dan dipangkas tidak dijelaskan secara rinci kepada pembaca, karena seluruhnya ditangani secara otomatis oleh pustaka yang digunakan.

Penelitian kedua oleh Rifania, Saniman, & Azlan (2023) dalam Jurnal Sistem Informasi Triguna Dharma (JURSI TGD) berjudul "Penerapan Algoritma Apriori Dalam Mencari Pola Pembelian Konsumen", menerapkan algoritma Apriori pada studi kasus toko/retail dengan skala transaksi yang relatif kecil. Pendekatan studi kasus seperti ini umum dilakukan pada penelitian sejenis di lingkup mahasiswa Teknik Informatika di Indonesia, namun konsekuensinya variasi produk dan pola asosiasi yang dapat ditemukan menjadi terbatas, karena jumlah transaksi dan jenis produk yang diamati tidak terlalu besar.

Penelitian ketiga oleh Oktaviani (2024) dalam jurnal JATI (Jurnal Mahasiswa Teknik Informatika) berjudul "Implementasi Algoritma Apriori untuk Analisis Pola Pembelian Konsumen pada Toko Serba", juga menerapkan pendekatan serupa pada studi kasus satu toko spesifik. Penelitian ini berhasil menemukan pola pembelian konsumen pada toko tersebut, namun tidak membahas aspek efisiensi komputasi dari algoritma Apriori itu sendiri misalnya seberapa besar pengurangan jumlah kandidat itemset yang dihasilkan oleh proses pruning dibandingkan jika seluruh kombinasi dicek tanpa pruning.

Penelitian keempat oleh Purwati & Karnila (2023) dalam Jurnal Sistem Informasi Bisnis berjudul "Strategi Peningkatan Penjualan Produk Menggunakan Market Basket Analysis", lebih menitikberatkan pembahasan pada sisi strategi bisnis yang dapat diambil dari hasil association rules, seperti penataan produk dan promosi. Pembahasan teknis mengenai

tahapan algoritma yang digunakan untuk menghasilkan rules tersebut relatif singkat, karena fokus penelitian memang lebih condong ke arah implikasi bisnisnya.

Penelitian kelima oleh Rana & Mondal (2021) dalam European Journal of Information Technologies and Computer Science berjudul "A Seasonal and Multilevel Association Based Approach for Market Basket Analysis in Retail Supermarket", mengusulkan pendekatan yang lebih kompleks dibanding Apriori standar, yaitu menambang pola musiman (seasonal) dan asosiasi multilevel pada data transaksi supermarket di Bangladesh. Penelitian ini berhasil menemukan ratusan pola musiman tambahan dan lebih dari seribu seasonal association rules di luar aturan reguler, pada nilai minimum support 0,1%. Meskipun pendekatannya lebih kaya secara informasi, penelitian ini tidak menyertakan perbandingan kompleksitas komputasi terhadap pendekatan dasar (misalnya brute force), sehingga efisiensi algoritmik dari pendekatan yang diusulkan tidak terukur secara kuantitatif.

Ringkasan kelima penelitian terdahulu tersebut, beserta kekurangan dan posisi penelitian ini sebagai usulan penyempurnaan, disajikan pada tabel berikut.

Tabel 2.1. Penelitian Terdahulu

No	Penelitian Terdahulu	Kekurangan	Usulan
1	Febrianto & Supriyanto (2022)	Proses internal algoritma tidak transparan karena menggunakan pustaka siap pakai	Implementasi Algoritma Apriori dibangun manual dari nol agar setiap tahapan dapat dijelaskan dan diverifikasi
2	Rifania, Saniman, & Azlan (2023)	Skala data transaksi kecil sehingga variasi pola asosiasi terbatas	Menggunakan dataset publik berskala lebih besar (7.501 transaksi, 120 produk unik)
3	Oktaviani (2024)	Tidak membahas efisiensi komputasi algoritma	Menyertakan analisis kuantitatif perbandingan jumlah kandidat Apriori vs brute force
4	Purwati & Karnila (2023)	Pembahasan teknis algoritma relatif singkat	Menjelaskan tahapan teknis algoritma secara rinci pada BAB 3 dan BAB 4
5	Rana & Mondal (2021)	Pendekatan kompleks namun tanpa pengukuran efisiensi komputasi	Mengukur secara eksplisit pengurangan jumlah kandidat akibat <i>pruning</i>

Berdasarkan kelima penelitian terdahulu tersebut, dapat disimpulkan bahwa mayoritas penelitian sejenis memilih salah satu dari dua jalur: 1. Menggunakan pustaka *data mining* siap pakai sehingga lebih cepat dikerjakan namun kurang transparan secara teknis, atau 2. Mengembangkan pendekatan yang lebih kompleks namun tanpa disertai bukti kuantitatif mengenai efisiensi algoritmiknya. Penelitian ini memposisikan diri di antara kedua jalur tersebut: mengimplementasikan algoritma Apriori standar secara manual (agar transparan secara teknis) sekaligus menyertakan bukti kuantitatif efisiensi melalui perbandingan jumlah kandidat yang dievaluasi dibandingkan pendekatan *brute force*, pada dataset publik berskala cukup besar (*Market Basket Optimisation*, 7.501 transaksi).

2.2. Landasan Teori

2.2.1. Data Mining

Data Mining adalah proses untuk menemukan pola, hubungan, atau pengetahuan baru yang tersembunyi dari sekumpulan data berukuran besar, yang secara umum tidak dapat ditemukan hanya dengan melihat data secara manual (Buulolo, 2020). Data Mining merupakan salah satu tahapan inti dari proses yang lebih besar yang disebut Knowledge Discovery in Databases (KDD), yang terdiri dari beberapa tahap:

1. Selection memilih data yang relevan dari sumber data
2. Preprocessing membersihkan data dari nilai kosong/tidak konsisten
3. Transformation mengubah data ke bentuk yang sesuai untuk diproses;
4. Data mining menerapkan algoritma untuk menemukan pola; dan
5. Interpretation/evaluation menafsirkan pola yang ditemukan menjadi pengetahuan yang bermanfaat.

Beberapa tugas umum dalam Data Mining antara lain klasifikasi, klustering, regresi, dan association rule mining yang menjadi fokus utama penelitian ini.

2.2.2. Knowledge Discovery in Database (KDD)

Knowledge Discovery in Database (KDD) adalah keseluruhan proses non-trivial untuk mengidentifikasi pola yang valid, baru, bermanfaat, dan dapat dipahami dari sekumpulan data, di mana Data Mining merupakan salah satu tahapan inti di dalamnya (Buulolo, 2020). Secara konseptual, KDD tidak hanya sekadar menerapkan algoritma pada data mentah, melainkan merupakan serangkaian langkah sistematis yang bersifat iterative artinya, proses ini dapat diulang dan disempurnakan pada setiap tahapannya hingga pengetahuan yang dihasilkan benar-benar bermakna dan dapat diandalkan untuk pengambilan keputusan.

Tahapan KDD secara umum terdiri dari lima langkah utama yang saling berkaitan. Pertama, selection, yaitu proses memilih dan mengekstrak subset data yang relevan dari sumber data yang tersedia sesuai dengan tujuan analisis. Tahap ini penting karena tidak semua data yang tersimpan dalam basis data akan digunakan; hanya data yang berkaitan langsung dengan permasalahan yang perlu diambil. Kedua, preprocessing, yaitu tahap pembersihan data dari nilai kosong (missing values), data duplikat, atau nilai yang tidak konsisten yang dapat mengganggu kualitas analisis. Ketiga, transformation, yaitu mengubah data ke dalam format atau representasi yang sesuai untuk diproses oleh algoritma tertentu, misalnya normalisasi, diskretisasi, atau encoding data kategorikal. Keempat, data mining, yaitu inti dari seluruh proses KDD

di mana algoritma-algoritma tertentu seperti Apriori, K-Means, atau Decision Tree diterapkan untuk menemukan pola tersembunyi dalam data. Kelima, interpretation/evaluation, yaitu tahap menafsirkan pola-pola yang ditemukan dan mengevaluasi apakah pola tersebut benar-benar valid, baru, dan bermanfaat untuk dijadikan pengetahuan yang dapat ditindaklanjuti.

Pada penelitian ini, kelima tahapan KDD tersebut tercermin secara menyeluruh dalam alur kerja yang dilakukan, mulai dari pengumpulan dan seleksi data, preprocessing dan transformasi data, penerapan algoritma Apriori sebagai tahap data mining, hingga interpretasi dan evaluasi association rules yang dihasilkan.

2.2.3. Association Rule

Association Rule (aturan asosiasi) adalah teknik Data Mining yang bertujuan menemukan hubungan atau keterkaitan antar item dalam suatu basis data transaksi, yang dinyatakan dalam bentuk aturan implikasi $A \rightarrow B$ ("jika A, maka B"). Dalam konteks ini, sebuah transaksi adalah satu kejadian pembelian yang terdiri dari satu atau lebih item, dan itemset adalah kumpulan satu atau lebih item yang muncul bersama dalam transaksi.

Sebuah itemset disebut frequent itemset apabila proporsi kemunculannya pada seluruh transaksi (nilai support-nya) memenuhi atau melebihi suatu ambang batas yang disebut minimum support. Konsep support dan confidence sebagai dasar pembentukan association rule pertama kali diperkenalkan oleh (Agrawal et al., 1993), dan menjadi kerangka kerja standar yang digunakan hingga saat ini, termasuk pada algoritma Apriori

2.2.4. Market Basket Analysis

Market Basket Analysis adalah salah satu bentuk penerapan Association Rule Mining yang secara khusus digunakan untuk menganalisis kebiasaan pembelian konsumen, dengan tujuan menemukan kombinasi produk yang sering dibeli secara bersamaan dalam satu transaksi belanja (Purwati & Karnila, 2023). Istilah "market basket" atau keranjang belanja merujuk pada kumpulan produk yang dibeli oleh seorang pelanggan dalam satu kunjungan belanja, sehingga analisis ini berusaha menjawab pertanyaan seperti: "Produk apa saja yang cenderung dibeli bersama-sama oleh pelanggan?"

Hasil dari Market Basket Analysis berupa association rules aturan asosiasi yang menggambarkan hubungan antara satu produk atau kelompok produk dengan produk lainnya. Aturan ini diukur menggunakan metrik seperti support (seberapa sering suatu kombinasi produk muncul dalam seluruh transaksi), confidence (seberapa besar kemungkinan produk B dibeli jika produk A sudah dibeli), dan lift (seberapa jauh hubungan antara produk A dan B melebihi kebetulan semata). Ketiga metrik ini menjadi dasar evaluasi untuk menentukan apakah suatu aturan asosiasi cukup kuat dan relevan secara bisnis.

Secara praktis, hasil Market Basket Analysis dapat langsung diterjemahkan menjadi berbagai strategi bisnis yang konkret, antara lain: penataan tata letak rak produk di supermarket agar produk yang sering dibeli bersama

diletakkan berdekatan, merancang paket bundling atau promosi lintas produk, memberikan rekomendasi produk yang dipersonalisasi kepada pelanggan secara digital, serta optimasi manajemen stok berdasarkan pola pembelian. Algoritma Apriori merupakan salah satu metode yang paling umum digunakan untuk melakukan Market Basket Analysis, karena mampu menemukan pola kombinasi produk tersebut secara sistematis melalui pembentukan frequent itemset dan pembangkitan association rules.

2.2.5. Algoritma Apriori

Pengertian. Algoritma Apriori adalah algoritma klasik dalam Association Rule Mining yang diperkenalkan oleh (Agrawal & Srikant, 1994) digunakan untuk menemukan seluruh frequent itemset dalam basis data transaksi melalui pendekatan iteratif candidate generation and test. Nama "Apriori" sendiri berasal dari fakta bahwa algoritma ini menggunakan pengetahuan "sebelumnya" (a priori knowledge) mengenai itemset frequent pada level sebelumnya, untuk membatasi pencarian kandidat pada level berikutnya.

Cara kerja. Algoritma ini bekerja secara berulang (iteratif) per level ukuran itemset, dengan langkah-langkah berikut:

1. Menghitung support setiap item tunggal (1-itemset) dari seluruh transaksi, lalu menyaring item yang memenuhi minimum support → menghasilkan frequent itemset level-1 (L_1).
2. Membentuk kandidat itemset level-($k+1$) dengan menggabungkan pasangan frequent itemset level- k yang memiliki $k-1$ item yang sama (join step).
3. Memangkas kandidat yang memiliki subset berukuran- k yang tidak termasuk frequent itemset level- k (prune step), berdasarkan Apriori Property: "jika suatu itemset tidak frequent, maka seluruh superset dari itemset tersebut juga pasti tidak frequent."
4. Menghitung support kandidat yang tersisa setelah pruning, lalu menyaring berdasarkan minimum support → menghasilkan L_{k+1} .
5. Mengulangi langkah 2–4 hingga tidak ada lagi kandidat baru yang frequent ditemukan.
6. Membentuk association rules dari seluruh frequent itemset yang ditemukan (ukuran ≥ 2), menghitung confidence dan lift setiap kemungkinan aturan, lalu menyaring aturan berdasarkan minimum confidence.

Contoh ilustrasi sederhana. Misalkan terdapat 5 transaksi sebagai berikut, dengan minimum support = 0,4 (setara 2 dari 5 transaksi):

Transaksi	Item
T1	Roti, Susu, Telur
T2	Roti, Susu
T3	Susu, Telur
T4	Roti, Susu, Telur, Mentega
T5	Roti, Telur

- Level 1: $\{Roti\}=0,8$; $\{Susu\}=0,8$; $\{Telur\}=0,8$ (ketiganya frequent); $\{Mentega\}=0,2 \rightarrow$ dibuang karena di bawah 0,4. Sehingga $L1 = \{Roti, Susu, Telur\}$.
- Level 2 (join step): Karena Mentega sudah dibuang di L1, kandidat level-2 yang dibentuk hanya dari kombinasi Roti, Susu, Telur yaitu $\{Roti, Susu\}$, $\{Roti, Telur\}$, $\{Susu, Telur\}$. Kandidat seperti $\{Roti, Mentega\}$ tidak pernah dibentuk sama sekali, karena Mentega sudah gugur di level sebelumnya inilah inti efisiensi pruning Apriori. Ketiga kandidat ini masing-masing memiliki support 0,6, sehingga ketiganya frequent $\rightarrow L2 = \{Roti, Susu\}$, $\{Roti, Telur\}$, $\{Susu, Telur\}$.
- Level 3 (join + Apriori Property check): Hanya ada satu kandidat yang mungkin, yaitu $\{Roti, Susu, Telur\}$. Sebelum dihitung support-nya, terlebih dahulu dicek Apriori Property: apakah ketiga subset berukuran-2 dari kandidat ini $\{Roti, Susu\}$, $\{Roti, Telur\}$, $\{Susu, Telur\}$ semuanya ada di L2? Ya, semuanya ada, sehingga kandidat ini valid untuk dihitung. Supportnya = 0,4 (muncul di T1 dan T4) $\rightarrow$ tepat memenuhi minimum support $\rightarrow$ frequent. Karena tidak ada kandidat level-4 yang mungkin dibentuk lagi, proses berhenti di sini.

Kelebihan:

- Mudah dipahami dan diimplementasikan karena logikanya sederhana dan sistematis, sebagaimana ditunjukkan pada contoh di atas.
- Prinsip pruning berbasis Apriori Property secara signifikan mengurangi jumlah kandidat yang perlu dievaluasi dibandingkan pendekatan brute force yang mengecek seluruh kemungkinan kombinasi tanpa terkecuali.

- Hasilnya bersifat lengkap (complete) algoritma dijamin menemukan seluruh frequent itemset yang memenuhi minimum support, tidak ada yang terlewat.
- Sudah digunakan dan diteliti secara luas selama lebih dari dua dekade, sehingga karakteristik dan keterbatasannya sudah dipahami dengan baik oleh komunitas riset Data Mining.

Kekurangan:

- Membutuhkan beberapa kali pemindaian (scan) penuh terhadap seluruh data transaksi, yaitu satu kali untuk setiap level ukuran itemset, yang dapat memperlambat proses pada data yang sangat besar.
- Pada dataset dengan jumlah item unik yang banyak dan minimum support yang sangat kecil, jumlah kandidat yang dihasilkan pada level-level awal tetap dapat sangat besar sebelum proses pruning bekerja secara efektif, sehingga kebutuhan memori dan waktu komputasi tetap signifikan.
- Algoritma ini tidak memperhitungkan urutan waktu pembelian (kapan item dibeli), sehingga tidak dapat menangkap pola sekuensial atau musiman seperti pada pendekatan yang lebih kompleks (Rana & Mondal, 2021).

2.2.6. One-Hot Encoding

One-Hot Encoding adalah teknik transformasi data yang digunakan untuk mengubah data kategorikal menjadi representasi biner (0 dan 1), di mana setiap kategori atau nilai unik dalam suatu variabel diwakili oleh satu kolom tersendiri nilai 1 menandakan kehadiran kategori tersebut dalam suatu observasi, sedangkan nilai 0 menandakan ketidakhadirannya (Ana et al., 2022). Teknik ini sangat umum diterapkan dalam pra-pemrosesan data sebelum analisis lebih lanjut, karena banyak algoritma machine learning dan data mining tidak dapat memproses data dalam bentuk teks atau kategori secara langsung, sehingga membutuhkan representasi numerik yang eksplisit.

Keunggulan One-Hot Encoding dibandingkan teknik encoding lain seperti label encoding adalah bahwa teknik ini tidak mengasumsikan adanya urutan atau hierarki antar-kategori. Misalnya, jika label encoding memberikan nilai 1, 2, dan 3 untuk kategori "Apel", "Mangga", dan "Jeruk", algoritma dapat salah menginterpretasikan bahwa "Jeruk" lebih besar dari "Apel", padahal keduanya hanya berbeda jenis. One-Hot Encoding menghindari bias ini dengan mewakili masing-masing kategori secara independen dalam kolom binernya sendiri.

Pada penelitian ini, One-Hot Encoding diterapkan secara manual untuk mengubah data transaksi yang awalnya berbentuk daftar produk per baris menjadi matriks biner berukuran 7.501×120 , di mana setiap baris merepresentasikan satu transaksi dan setiap kolom merepresentasikan satu dari 120 produk unik yang teridentifikasi dalam dataset. Matriks ini digunakan sebagai representasi pelengkap untuk keperluan eksplorasi dan visualisasi data, meskipun struktur ini tidak

digunakan secara langsung dalam komputasi inti algoritma Apriori yang menggunakan representasi transaksi berbasis list.

2.2.7. Support

$$\text{Support}(A) = \frac{\text{jumlah transaksi yang memuat } A}{\text{total transaksi}}$$

Support mengukur popularitas sebuah itemset secara keseluruhan, tanpa memandang konteks item lain (Agrawal et al., 1993). Pada contoh ilustrasi di atas, $\text{support}(\{\text{Roti}\}) = 0,8$ berarti Roti muncul pada 80% dari seluruh transaksi yang diamati.

2.2.8. Confidence

$$\text{Confidence}(A \rightarrow B) = \frac{\text{Support}(A \cup B)}{\text{Support}(A)}$$

Confidence mengukur tingkat keyakinan suatu aturan, yaitu proporsi transaksi yang memuat B di antara transaksi-transaksi yang memuat A (Agrawal et al., 1993). Sifatnya searah (asimetris) $\text{confidence}(A \rightarrow B)$ tidak sama dengan $\text{confidence}(B \rightarrow A)$. Pada contoh ilustrasi, $\text{confidence}(\text{Roti} \rightarrow \text{Susu}) = 0,6/0,8 = 0,75$, artinya 75% pembeli Roti juga membeli Susu.

2.2.9. Lift Ratio

$$\text{Lift}(A \rightarrow B) = \frac{\text{Confidence}(A \rightarrow B)}{\text{Support}(B)}$$

Lift mengukur apakah hubungan antar item bersifat nyata atau hanya kebetulan akibat popularitas item B yang sudah tinggi, dan umum digunakan sebagai uji akurasi/kekuatan korelasi suatu aturan asosiasi (Karina et al., 2022).

Melanjutkan contoh ilustrasi: $\text{lift}(\text{Roti} \rightarrow \text{Susu}) = 0,75 / 0,8 = 0,9375$. Karena nilainya lebih kecil dari 1, meskipun confidence-nya terlihat tinggi (75%), hubungan Roti dan Susu sebenarnya sedikit lebih rendah dibandingkan jika keduanya dibeli secara independen/acak ini terjadi karena Susu sendiri sudah sangat populer (80% transaksi), sehingga tingginya confidence sebagian besar disebabkan oleh popularitas Susu itu sendiri, bukan karena hubungan khusus dengan Roti.

Inilah sebabnya nilai lift dianggap lebih andal dibanding confidence saja dalam menilai kekuatan hubungan antar item: $\text{lift} > 1$ menunjukkan hubungan positif, $\text{lift} = 1$ menunjukkan independensi, dan $\text{lift} < 1$ menunjukkan hubungan negatif.

2.2.10. Dataset Market Basket Optimisation

Market Basket Optimisation adalah dataset publik yang tersedia di platform Kaggle, berisi 7.501 data transaksi pembelian pelanggan supermarket dengan struktur 20 kolom yang merepresentasikan slot produk per transaksi (d4rklucif3r, n.d.). Dataset ini dipublikasikan secara terbuka dan dapat diakses oleh siapa pun untuk keperluan penelitian, pembelajaran, maupun pengembangan model analisis data.

Dari sisi strukturnya, dataset ini tidak memiliki baris header; setiap baris merepresentasikan satu transaksi belanja yang dapat memuat antara 1 hingga 20 produk. Kolom-kolom yang kosong pada suatu baris menandakan bahwa transaksi tersebut hanya memuat lebih sedikit produk dari kapasitas maksimum. Secara keseluruhan, dataset ini mengandung 120 produk unik yang teridentifikasi dari seluruh transaksi yang ada, mencakup berbagai kategori seperti buah-buahan, sayuran, produk susu, minuman, dan sebagainya yang umum ditemukan di supermarket.

Dataset ini banyak digunakan sebagai benchmark dalam literatur Association Rule Mining karena ukurannya yang representative cukup besar untuk menghasilkan pola yang bermakna secara statistik, namun tetap terjangkau secara komputasi. Karakteristik ini menjadikannya pilihan yang tepat sebagai basis studi Market Basket Analysis, termasuk dalam penelitian ini, di mana seluruh proses mulai dari preprocessing hingga interpretasi association rules dilakukan terhadap dataset ini.

2.2.11. Python

Python adalah bahasa pemrograman tingkat tinggi yang bersifat interpreted, dinamis, dan berorientasi objek, serta dikenal karena sintaksnya yang bersih dan mudah dipelajari (Angelina M. T. I. Sambu et al., 2023). Python saat ini menjadi salah satu bahasa pemrograman paling populer di dunia dan banyak digunakan dalam berbagai bidang seperti pengembangan perangkat lunak, kecerdasan buatan, pengembangan web, machine learning, dan analisis data.

Salah satu keunggulan utama Python dalam konteks ilmu data dan data mining adalah tersedianya ekosistem pustaka (library) yang sangat kaya. Pustaka-pustaka seperti NumPy, pandas, scikit-learn, dan Matplotlib memungkinkan pengembang dan peneliti untuk melakukan berbagai tugas analisis data secara efisien tanpa perlu membangun semuanya dari nol. Selain itu, Python juga menyediakan pustaka bawaan (built-in) seperti itertools dan collections yang sangat berguna untuk operasi-operasi kombinatorik dan pengelolaan struktur data.

Dalam penelitian ini, Python dipilih sebagai bahasa pemrograman utama karena beberapa alasan. Pertama, sintaksnya yang sederhana dan mudah dibaca memungkinkan fokus pada logika algoritma tanpa terganggu oleh kompleksitas bahasa. Kedua, pustaka bawaan itertools dan collections dimanfaatkan secara langsung untuk membangun algoritma Apriori secara manual mulai dari pembangkitan kandidat itemset, penghitungan support, hingga pembentukan association rules tanpa bergantung pada pustaka eksternal khusus data mining.

Pendekatan implementasi manual ini dipilih untuk memberikan pemahaman yang lebih mendalam tentang cara kerja algoritma dari akar-akarnya.

2.2.12. Pandas

Pandas adalah pustaka (library) Python sumber terbuka yang dirancang khusus untuk manipulasi dan analisis data secara efisien dan fleksibel, terutama untuk data dalam bentuk tabular seperti file CSV, Excel, atau basis data relasional (Angelina M. T. I. Sambu et al., 2023). Nama "pandas" berasal dari gabungan kata "panel data" dan "Python data analysis", yang mencerminkan akar pengembangan pustaka ini untuk analisis data panel yang sering dijumpai dalam ekonometri dan statistik.

Inti dari pustaka pandas adalah struktur data `DataFrame` sebuah tabel dua dimensi berindeks yang menyerupai spreadsheet atau tabel basis data serta struktur `Series` untuk data satu dimensi. Dengan `DataFrame`, pengguna dapat dengan mudah melakukan berbagai operasi pengolahan data seperti pembacaan file, pemilihan kolom dan baris, filtering, pengelompokan (`groupby`), penggabungan (`merge/join`), serta transformasi data, semuanya dengan sintaks yang ringkas dan intuitif.

Pada penelitian ini, pustaka pandas digunakan secara ekstensif dalam tahap preprocessing dan eksplorasi data. Secara spesifik, fungsi `pd.read_csv()` digunakan untuk memuat dataset dari file CSV ke dalam `DataFrame`; atribut `shape` dan metode `info()` digunakan untuk memeriksa dimensi dan tipe data; serta metode `dropna()` digunakan untuk menghapus nilai kosong (NaN) yang muncul akibat transaksi yang memiliki jumlah produk lebih sedikit dari 20 kolom yang tersedia. Proses-proses ini dijelaskan secara rinci pada BAB 4.1.

BAB 3

METODOLOGI PENELITIAN

3.1. Kerangka Berpikir

Sebagaimana digambarkan pada diagram kerangka berpikir di atas, penelitian ini disusun melalui lima tahap yang saling berurutan dan saling bergantung satu sama lain keluaran (output) dari satu tahap menjadi masukan (input) bagi tahap berikutnya. Pendekatan bertahap ini dipilih karena karakteristik algoritma Apriori itu sendiri yang bersifat iteratif dan bertingkat (level-wise), setiap level frequent itemset hanya dapat dibentuk setelah level sebelumnya selesai diproses dan divalidasi, sehingga kualitas hasil pada tahap akhir (association rules) sangat bergantung pada ketelitian tahap-tahap sebelumnya, terutama tahap preprocessing data.

Tabel 3.1. Kerangka Berfikir

TAHAP	INPUT	PROSES	OUTPUT
Pengumpulan Data	Dataset csv (7.501×20)	Baca dataset (pandas)	DataFrame 7.501×20
Preprocessing	DataFrame mentah	Bersihkan NaN → list & set	List & set transaksi bersih
Algoritma Apriori	List & set, min_sup = 0,02	Candidate gen, pruning	103 frequent itemset
Pembentukan Rules	Itemset, min_conf = 0,2	Hitung confidence & lift	55 association rules
Analisis Hasil	Itemset & rules	Visualisasi & interpretasi	Pola pembelian & rekomendasi

Pada tahap Pengumpulan Data, input berupa berkas dataset Market Basket Optimisation (7.501 baris, 20 kolom), proses-nya adalah pembacaan berkas menggunakan pustaka pandas, sehingga menghasilkan output berupa DataFrame mentah berukuran 7.501×20. DataFrame ini kemudian menjadi input bagi tahap Preprocessing, di mana proses-nya adalah membersihkan nilai kosong (NaN) dan mengubah data menjadi struktur list dan set, menghasilkan output berupa 7.501 list dan set transaksi yang sudah bersih.

Hasil tersebut menjadi input bagi tahap Algoritma Apriori, bersama dengan parameter `min_support = 0,02` yang ditentukan sebelumnya. Proses pada tahap ini meliputi candidate generation dan pruning secara manual, menghasilkan output berupa 103 frequent itemset. Selanjutnya, frequent itemset tersebut menjadi input bagi tahap Pembentukan Rules, bersama parameter `min_confidence = 0,2` proses-nya adalah menghitung nilai confidence dan lift setiap kemungkinan aturan, menghasilkan output berupa 55 association rules.

Pada tahap akhir, Analisis Hasil, input-nya adalah seluruh frequent itemset dan association rules yang telah ditemukan; proses-nya berupa visualisasi dan interpretasi; output-


nya adalah pemahaman mengenai pola pembelian konsumen yang dapat dimanfaatkan sebagai rekomendasi bisnis. Struktur swimlane ini menggambarkan secara jelas bagaimana output dari satu tahap selalu menjadi input bagi tahap berikutnya, mencerminkan alur kerja yang saling berkaitan dan bergantung satu sama lain di sepanjang proses penelitian.

3.2. Pengumpulan dan Pengolahan Data

Proses pengumpulan dan pengolahan data pada penelitian ini dijelaskan melalui flowchart dan narasi deskriptif pada masing-masing tahapnya, yang melanjutkan kerangka berpikir. Pembahasan dibagi menjadi dua bagian, yaitu Pengumpulan Data yang menjelaskan sumber dan karakteristik dataset, serta Pengolahan Data yang menjelaskan tahapan pembersihan dan transformasi data hingga siap digunakan oleh algoritma Apriori.

3.2.1. Pengumpulan Data

Data yang digunakan dalam penelitian ini diperoleh secara sekunder dari dataset publik Market Basket Optimisation dalam format `Market_Basket_Optimisation.csv`, yang tersedia secara terbuka di platform Kaggle. Karakteristik utama dataset ini adalah tidak memiliki baris header, sehingga setiap baris dalam file langsung merepresentasikan satu transaksi belanja, dan setiap kolom (indeks 0 sampai 19) merepresentasikan slot urutan produk yang dibeli pada transaksi tersebut bukan kategori produk tertentu, karena urutan kolom tidak memiliki makna khusus.




Gambar 3.2.1. Flowcart Pengumpulan Data

Dataset terdiri dari 7.501 transaksi dan 20 kolom, dengan total 120.657 nilai kosong (NaN) yang tersebar di berbagai kolom. Dataset kemudian diunduh dan dimuat ke dalam lingkungan Python menggunakan `pd.read_csv(header=None)` parameter `header=None` digunakan karena baris pertama file merupakan data transaksi, bukan judul kolom menghasilkan DataFrame mentah berukuran 7.501 baris dan 20 kolom

3.2.2. Pengolahan Data

Pengolahan data dirancang untuk mengubah data tabular mentah menjadi struktur data yang efisien untuk operasi yang akan dilakukan berulang-ulang oleh algoritma Apriori, yaitu pengecekan keanggotaan item dalam suatu transaksi. Tahapan yang dilakukan adalah sebagai berikut:



Gambar 3.2.2 Flowcart Pengolahan Data

1. Eksplorasi awal memeriksa ukuran dataset (`shape`), tipe data setiap kolom (`info()`), dan jumlah missing value pada setiap kolom, untuk memastikan struktur data dipahami sepenuhnya sebelum diproses lebih lanjut. Pada tahap ini juga diidentifikasi jumlah produk unik yang ada di seluruh dataset, yaitu sebanyak 120 produk.
2. Transformasi ke list transaksi setiap baris data diambil, nilai NaN dibuang menggunakan `dropna()` agar slot kolom kosong tidak ikut diproses sebagai "produk", kemudian hasilnya diubah menjadi list nama produk per transaksi. Hasil tahap ini adalah struktur list of list berisi 7.501 transaksi yang sudah bersih dari nilai kosong.

3. Konversi ke set setiap list transaksi selanjutnya diubah menjadi tipe data set Python. Langkah ini penting secara teknis: pengecekan keanggotaan item (in) maupun subset (`issubset()`) pada struktur set memiliki kompleksitas waktu rata-rata $O(1)$, jauh lebih cepat dibandingkan struktur list yang membutuhkan $O(n)$ untuk operasi yang sama. Karena algoritma Apriori akan melakukan pengecekan subset ini secara berulang ribuan kali (satu kali per kandidat itemset, per transaksi), pemilihan struktur data ini berdampak langsung pada waktu eksekusi keseluruhan program.
4. One-hot encoding manual sebagai pelengkap eksplorasi data, dibuat juga representasi matriks biner berukuran 7.501×120 (baris = transaksi, kolom = 120 produk unik, nilai 1 jika produk dibeli pada transaksi tersebut). Representasi ini berguna untuk eksplorasi visual dan validasi data, namun tidak digunakan langsung dalam komputasi inti algoritma Apriori, karena pengecekan subset pada struktur set (langkah 3) tetap lebih efisien dibandingkan menelusuri matriks kolom demi kolom untuk setiap kandidat itemset.

3.3. Perancangan Teknik/Model (*Kebaharuan*)

Kebaharuan utama penelitian ini terletak pada pendekatan implementasi algoritma Apriori secara manual dari nol, tanpa menggunakan pustaka data mining siap pakai seperti `mlxtend`. Sebagaimana yang telah dibahas, mayoritas penelitian sejenis memanggil fungsi `apriori()` dan `association_rules()` yang bersifat black-box proses internalnya tidak terlihat dan tidak dapat dijelaskan secara teknis. Pada penelitian ini, seluruh tahapan inti algoritma dirancang dan diimplementasikan sendiri melalui tiga fungsi utama yang saling terhubung:

1. `hitung_support(itemset, transactions_set, total_transaksi)` fungsi dasar yang menghitung nilai support sebuah itemset, dengan menghitung proporsi transaksi (dari struktur set) yang memuat seluruh anggota itemset tersebut melalui operasi `itemset.issubset(transaksi)`. Fungsi ini dipanggil berulang kali oleh fungsi `apriori_manual()` pada setiap level.
2. `apriori_manual(transactions, transactions_set, total_transaksi, min_support)` fungsi inti yang mengimplementasikan seluruh siklus algoritma Apriori sesuai langkah teori (candidate generation, support counting, pruning, validasi Apriori Property), dan mengembalikan dictionary `{frozenset(itemset): nilai_support}`. Pada eksekusi penelitian ini dengan `min_support = 0,02`, fungsi tersebut menghasilkan: Level 1 dari 120 kandidat 1-itemset

(seluruh produk unik), ditemukan 53 frequent itemset, dan dibentuk 1.378 kandidat untuk level berikutnya; Level 2 dari 1.378 kandidat tersebut, ditemukan 50 frequent itemset, dan hanya 61 kandidat yang lolos validasi Apriori Property untuk diuji pada level 3; Level 3 tidak satu pun dari 61 kandidat tersebut memenuhi `min_support`, sehingga proses berhenti dengan total 103 frequent itemset (53 + 50) yang ditemukan secara keseluruhan. Pola ini secara konkret membuktikan cara kerja pruning yang dijelaskan secara teoritis pada bab sebelumnya, jumlah kandidat yang dievaluasi menyusut drastis pada setiap level (dari 120, ke 1.378, ke hanya 61), jauh lebih kecil dibandingkan jika seluruh kombinasi tanpa pruning harus dicek satu per satu.

3. `buat_rules_manual(frequent_itemsets, transactions_set, total_transaksi, min_confidence)` fungsi yang membentuk seluruh kemungkinan pasangan antecedent-consequent dari setiap frequent itemset berukuran ≥ 2 menggunakan `combinations()` dari pustaka bawaan Python, lalu menghitung nilai confidence dan lift setiap kemungkinan aturan secara langsung berdasarkan rumus matematisnya (bukan melalui fungsi pustaka eksternal). Pada eksekusi penelitian ini dengan `min_confidence = 0,2`, fungsi tersebut menghasilkan total 55 association rules.

Pendekatan perancangan ini memberikan dua kontribusi utama: pertama, transparansi teknis setiap langkah algoritma dapat dijelaskan, diverifikasi, dan ditelusuri kembali ke baris kode tertentu, sesuatu yang tidak mungkin dilakukan ketika menggunakan fungsi black-box, kedua, bukti kuantitatif efisiensi angka-angka konkret seperti pengurangan dari 120 menjadi 1.378 lalu hanya 61 kandidat pada tiap level menjadi data nyata yang mendukung klaim efisiensi algoritma Apriori, bukan sekadar klaim teoritis tanpa bukti sebagaimana ditemukan pada sebagian penelitian terdahulu (BAB 2).

3.4. Evaluasi Teknik/Model (*Teknik Evaluasi*)

Evaluasi terhadap frequent itemset dan association rules yang dihasilkan dilakukan melalui dua pendekatan: evaluasi berbasis metrik dan evaluasi kebenaran implementasi.

Evaluasi berbasis metrik menggunakan tiga ukuran standar Association Rule Mining support, confidence, dan lift (rumus dan interpretasinya telah dijelaskan pada BAB 2). Nilai ambang batas yang digunakan adalah:

Tabel 3.4. Evaluasi

Parameter	Nilai	Pertimbangan Pemilihan
-----------	-------	------------------------

min_support	0,02 (2%)	Cukup rendah untuk menangkap produk-produk dengan frekuensi pembelian sedang, namun cukup tinggi untuk membatasi jumlah frequent itemset agar tetap relevan secara bisnis (tidak terlalu banyak itemset yang sangat jarang muncul)
min_confidence	0,2 (20%)	Ambang batas moderat yang umum digunakan pada penelitian sejenis (BAB 2), agar aturan yang dihasilkan cukup banyak untuk dianalisis namun tidak menyertakan aturan yang terlalu lemah keyakinannya
Interpretasi lift	> 1 / $=$ 1 / < 1	Digunakan untuk menyaring aturan yang benar-benar memiliki hubungan nyata ($\text{lift} > 1$) dari aturan yang confidence-nya tinggi hanya karena popularitas item itu sendiri

Itemset yang nilai support-nya berada di bawah min_support dibuang pada setiap level (tahap pruning sebagaimana dijelaskan pada 3.3), sehingga hanya itemset yang benar-benar sering muncul yang dilanjutkan ke pembentukan rules. Selanjutnya, aturan yang nilai confidence-nya di bawah min_confidence disaring keluar, dan aturan yang tersisa diurutkan berdasarkan nilai lift untuk mengidentifikasi pasangan produk dengan keterkaitan paling kuat.

Evaluasi kebenaran implementasi dilakukan untuk memastikan bahwa hasil yang diperoleh dari fungsi-fungsi manual (`hitung_support()`, `apriori_manual()`, `buat_rules_manual()`) benar secara matematis, bukan hanya berjalan tanpa error. Validasi dilakukan dengan menghitung ulang nilai support salah satu produk secara independen langsung dari data transaksi (tanpa melalui fungsi `apriori_manual()`), kemudian dibandingkan dengan nilai yang tersimpan pada `support_dict` hasil fungsi tersebut. Kesesuaian antara kedua hasil perhitungan ini menjadi bukti bahwa logika implementasi sudah sesuai dengan definisi matematis yang dijelaskan pada BAB 2.

BAB 4

IMPLEMENTASI DAN EKSPERIMEN

4.1. Persiapan Data

Bagian ini menjelaskan tahap persiapan data yang diperlukan untuk implementasi dan eksperimen. Persiapan data meliputi pengumpulan dan pengolahan data yang akan digunakan dalam penelitian.

4.1.1. Pengumpulan Data

Pada tahap implementasi, data yang digunakan adalah dataset publik Market Basket Optimisation yang diunduh dari platform Kaggle dalam format berkas `Market_Basket_Optimisation.csv`. Dataset ini tersedia secara bebas dan dapat diakses oleh publik tanpa memerlukan proses pengumpulan data primer seperti survei maupun eksperimen lapangan, sehingga proses akuisisi data dapat dilakukan secara langsung.

Proses pemuatan data dilakukan menggunakan pustaka *pandas* melalui fungsi `pd.read_csv('Market_Basket_Optimisation.csv', header=None)`. Parameter `header=None` disertakan karena baris pertama pada berkas CSV bukan merupakan baris judul kolom, melainkan data transaksi pertama itu sendiri. Apabila parameter ini tidak disertakan, *pandas* akan secara otomatis memperlakukan baris pertama sebagai nama kolom, sehingga transaksi pertama akan hilang dari analisis dan jumlah data yang diproses menjadi berkurang satu baris.

Hasil pemuatan data menunjukkan bahwa dataset terdiri dari 7.501 baris yang merepresentasikan transaksi pembelian dan 20 kolom yang merepresentasikan slot produk dalam satu transaksi. Struktur ini sesuai dengan deskripsi dataset yang telah dipaparkan pada BAB 3, sehingga data dapat langsung digunakan pada tahap preprocessing tanpa memerlukan penyesuaian struktur lebih lanjut.

4.1.2. Pengolahan Data

Setelah data berhasil dimuat, dilakukan eksplorasi awal untuk memahami struktur dan kualitas dataset sebelum proses pembersihan dimulai. Eksplorasi ini menggunakan fungsi `shape` dan `info()` dari pustaka *pandas*, yang menunjukkan bahwa dataset terdiri dari 7.501 baris dan 20 kolom dengan total 120.657 nilai kosong (NaN) yang tersebar di berbagai kolom, serta teridentifikasi 120 produk unik di seluruh dataset.

Tingginya jumlah nilai kosong tersebut bukan merupakan kesalahan data, melainkan merupakan konsekuensi logis dari struktur transaksi yang bervariasi. Setiap transaksi memiliki jumlah produk yang berbeda-beda, sementara setiap baris selalu dialokasikan 20 kolom. Transaksi dengan produk sedikit akan menyisakan kolom-kolom yang tidak terisi. Hal ini dapat dilihat secara konkret pada tiga transaksi pertama hasil *preprocessing* berikut:

- Transaksi 1: ['shrimp', 'almonds', 'avocado', 'vegetables mix', 'green grapes', 'whole wheat flour', 'yams', 'cottage cheese', 'energy drink', 'tomato juice', 'low fat yogurt', 'green tea', 'honey', 'salad', 'mineral water', 'salmon', 'antioxydant juice', 'frozen smoothie', 'spinach', 'olive oil'] 20 produk, mengisi seluruh kolom tanpa nilai kosong.

- Transaksi 2: ['burgers', 'meatballs', 'eggs'] 3 produk, menyisakan 17 kolom kosong sebelum dibersihkan.
- Transaksi 3: ['chutney'] 1 produk, menyisakan 19 kolom kosong sebelum dibersihkan.

Proses pembersihan data dilakukan dengan mengiterasi setiap baris menggunakan `df.iloc[i].dropna().tolist()`, yang secara bersamaan membuang nilai kosong dan mengubah setiap baris menjadi *list* produk yang valid. Hasil akhir tahap ini adalah struktur *list of list* berisi 7.501 transaksi bersih tanpa nilai kosong.

Selanjutnya, setiap *list* transaksi dikonversi menjadi struktur set Python sebagai contoh, Transaksi 1 menjadi {'shrimp', 'almonds', 'avocado', ...}. Konversi ini dilakukan karena operasi pengecekan subset (`issubset()`) pada struktur set memiliki kompleksitas waktu rata-rata $O(k)$, jauh lebih efisien dibandingkan struktur list yang membutuhkan $O(n \times m)$. Mengingat algoritma Apriori akan melakukan pengecekan ini sebanyak ribuan kali selama proses *candidate generation* dan *pruning*, pemilihan struktur data yang tepat berdampak signifikan terhadap kecepatan eksekusi secara keseluruhan.

Sebagai pelengkap eksplorasi, dibuat pula representasi *one-hot encoding* manual berupa matriks biner berukuran 7.501×120 , di mana nilai 1 menandakan produk tersebut ada dalam suatu transaksi dan nilai 0 menandakan sebaliknya. Meskipun struktur ini tidak digunakan dalam komputasi inti algoritma Apriori, matriks ini bermanfaat untuk keperluan visualisasi dan verifikasi distribusi produk secara menyeluruh.

4.2. Implementasi Teknik/Model

Bagian ini menjelaskan tahap persiapan data yang diperlukan untuk implementasi dan eksperimen. Persiapan data meliputi pengumpulan dan pengolahan data yang akan digunakan dalam penelitian.

4.2.1. Implementasi Algoritma Apriori Manual

Algoritma Apriori diimplementasikan melalui fungsi `apriori_manual(transactions, transactions_set, total_transaksi, min_support)` yang dijalankan dengan parameter `min_support = 0,02 (2%)` artinya hanya itemset yang muncul pada minimal 150 dari 7.501 transaksi yang dianggap *frequent*.

Fungsi dasar `hitung_support()` digunakan untuk menghitung proporsi transaksi yang memuat suatu itemset:

Kode Program 4.2.1a Fungsi `hitung_support()`

```
def hitung_support(itemset, transactions_set, total_transaksi):
    itemset = set(itemset)
    jumlah_muncul = sum(1 for transaksi in transactions_set if
        itemset.issubset(transaksi))
    return jumlah_muncul / total_transaksi
```


Fungsi `apriori_manual()` kemudian menerapkan seluruh siklus candidate generation, support counting, dan pruning secara iteratif:

Kode Program 4.2.1b Fungsi `apriori_manual()`

```
def apriori_manual(transactions, transactions_set, total_transaksi,
min_support):
    # Langkah 1: Kandidat awal -> seluruh produk unik sebagai itemset
    berukuran 1
    semua_item = set(item for transaksi in transactions for item in
transaksi)
    kandidat_saat_ini = [frozenset([item]) for item in semua_item]

    frequent_itemsets_dict = {}
    ukuran_itemset = 1

    while kandidat_saat_ini:
        # Langkah 2-3: Support Counting & Pruning
        support_level_ini = {}
        for kandidat in kandidat_saat_ini:
            nilai_support = hitung_support(kandidat,
transactions_set, total_transaksi)
            if nilai_support >= min_support:
                support_level_ini[kandidat] = nilai_support

        if not support_level_ini:
            break
        frequent_itemsets_dict.update(support_level_ini)

        # Langkah 4: Candidate Generation (join step)
        daftar_frequent = list(support_level_ini.keys())
        kandidat_berikutnya = set()
        for i in range(len(daftar_frequent)):
            for j in range(i + 1, len(daftar_frequent)):
                gabungan = daftar_frequent[i] | daftar_frequent[j]
                if len(gabungan) == ukuran_itemset + 1:
                    kandidat_berikutnya.add(gabungan)

        # Langkah 5: Apriori Property (prune step)
        kandidat_tervalidasi = []
        for kandidat in kandidat_berikutnya:
```

```

subset_k = combinations(kandidat, len(kandidat) - 1)
if all(frozenset(s) in support_level_ini for s in
subset_k):
    kandidat_tervalidasi.append(kandidat)

kandidat_saat_ini = kandidat_tervalidasi
ukuran_itemset += 1

return frequent_itemsets_dict

```

Baris `if len(gabungan) == ukuran_itemset + 1` pada Langkah 4 merupakan implementasi *join step*, sedangkan blok `all(frozenset(s) in support_level_ini ...)` pada Langkah 5 merupakan implementasi langsung dari Apriori Property yang dijelaskan pada BAB 2 kandidat hanya dipertahankan apabila seluruh subset berukuran-k-nya juga frequent pada level sebelumnya. Hasil eksekusi pada setiap level adalah sebagai berikut:

Tabel 4.2.1. Implementasi Algoritma Apriori

Level	Kandidat Dievaluasi	Frequent Itemset Ditemukan	Kandidat untuk Level Berikutnya
1	120	53	1.378
2	1.378	50	61
3	61	0 (proses berhenti)	–
Total	1.559	103	–

Menariknya, angka 1.378 kandidat di level 2 dapat diverifikasi secara matematis karena seluruh 53 frequent itemset di level 1 berukuran 1 (sehingga otomatis berbagi 0 item, syarat *join step*), maka jumlah kandidat 2-itemset yang terbentuk adalah seluruh kombinasi 2 dari 53 item, yaitu $C(53,2) = \frac{53 \times 52}{2} = 1.378$ tepat sama dengan hasil eksekusi program.

Hal ini membuktikan bahwa logika *join step* pada fungsi `apriori_manual()` bekerja sesuai definisi teoritis pada bab sebelumnya. Sebaliknya, jumlah kandidat di level 3 (61) jauh lebih kecil dibandingkan jika seluruh kombinasi 2 dari 50 frequent itemset level-2 digabungkan tanpa syarat ($C(50,2) = 1.225$), karena pada level ini *join step* hanya menggabungkan pasangan itemset yang berbagi tepat 1 item, dan hasilnya masih harus lolos validasi Apriori Property sebelum dihitung supportnya. Penyusutan dari 1.225 kemungkinan gabungan menjadi hanya 61 kandidat valid ini menunjukkan kontribusi nyata tahap *prune step* dalam algoritma.

4.2.2. Implementasi Pembentukan Association Rules

Dari 103 frequent itemset tersebut, fungsi `buat_rules_manual()` membentuk seluruh kemungkinan pasangan antecedent–consequent dari itemset berukuran ≥ 2

menggunakan `combinations()`, lalu menghitung confidence dan lift masing-masing berdasarkan rumus pada BAB 2.

Kode Program 4.2.1b Fungsi `buat_rules_manual()`

```
def buat_rules_manual(support_dict, min_confidence):
    daftar_rules = []

    for itemset in support_dict:
        if len(itemset) < 2:
            continue

        items = list(itemset)
        for ukuran_antecedent in range(1, len(items)):
            for antecedent_tuple in combinations(items,
ukuran_antecedent):
                antecedent = frozenset(antecedent_tuple)
                consequent = itemset - antecedent

                support_itemset = support_dict[itemset]      #
support(A U B)
                support_antecedent = support_dict[antecedent] #
support(A)
                support_consequent = support_dict[consequent] #
support(B)

                confidence = support_itemset / support_antecedent
                lift = confidence / support_consequent

                if confidence >= min_confidence:
                    daftar_rules.append({
                        'antecedents': antecedent,
                        'consequents': consequent,
                        'support': support_itemset,
                        'confidence': confidence,
                        'lift': lift
                    })

    return pd.DataFrame(daftar_rules)
```

Perhatikan bahwa baris `confidence = support_itemset / support_antecedent` dan `lift = confidence / support_consequent` merupakan

implementasi langsung dari rumus matematis pada BAB 2 (Sub-bab 2.2.5 dan 2.2.6), bukan hasil panggilan fungsi pustaka eksternal.

Sebagai contoh, untuk frequent itemset berukuran 2 seperti {ground beef, spaghetti}, fungsi ini membentuk dua kemungkinan rule berlawanan arah: ground beef $\rightarrow$ spaghetti dan spaghetti $\rightarrow$ ground beef, masing-masing dengan nilai confidence berbeda karena pembagi (support antecedent) yang berbeda. Hasil akhir setelah disaring dengan `min_confidence = 0,2` adalah 55 association rules.

4.3. Hasil dan Analisis

Bagian ini menjelaskan hasil dari implementasi dan eksperimen yang dilakukan. Analisis hasil dilakukan untuk mengevaluasi kinerja model yang diusulkan dan membandingkannya dengan model atau metode sebelumnya.

4.3.1. Interpretasi Kinerja Model

Karena penelitian ini menggunakan teknik *Association Rule Mining* yang bersifat *unsupervised* (tanpa label target), metrik kinerja klasik seperti akurasi, presisi, dan recall tidak relevan digunakan — metrik tersebut berlaku untuk model klasifikasi/prediksi, sedangkan tujuan penelitian ini adalah penemuan pola (*pattern discovery*). Sebagai gantinya, kinerja diukur melalui support, confidence, dan lift.

15 frequent itemset dengan support tertinggi:

Itemset	Support
mineral water	0,238
eggs	0,180
spaghetti	0,174
french fries	0,171
chocolate	0,164
green tea	0,132
milk	0,130
ground beef	0,098
frozen vegetables	0,095
pancakes	0,095
burgers	0,087
cake	0,081
cookies	0,080
escalope	0,079
low fat yogurt	0,077

10 association rules dengan nilai lift tertinggi:

Rule	Support	Confidence	Lift
ground beef $\rightarrow$ spaghetti	0,039	0,399	2,29
spaghetti $\rightarrow$ ground beef	0,039	0,225	2,29
olive oil $\rightarrow$ spaghetti	0,023	0,348	2,00

soup → mineral water	0,023	0,456	1,91
frozen vegetables → milk	0,024	0,248	1,91
burgers → eggs	0,029	0,330	1,84
olive oil → mineral water	0,028	0,419	1,76
tomatoes → spaghetti	0,021	0,306	1,76
ground beef → mineral water	0,041	0,417	1,75
ground beef → milk	0,022	0,224	1,73

Beberapa interpretasi penting dari tabel di atas:

- ground beef → spaghetti (confidence 39,9%, lift 2,29): pelanggan pembeli ground beef memiliki kemungkinan 2,29 kali lebih tinggi membeli spaghetti dibanding jika kedua produk independen — pola ini sangat logis karena keduanya bahan umum hidangan spaghetti bolognese.
- soup → mineral water (confidence 45,6%, lift 1,91): hampir separuh pembeli sup juga membeli air mineral, kemungkinan terkait kebiasaan membeli minuman pendamping makanan.
- olive oil → spaghetti dan tomatoes → spaghetti (lift 2,00 dan 1,76): memperkuat temuan bahwa spaghetti menjadi "pusat" dari beberapa pola pembelian bahan masakan Italia.

4.3.2. Evaluasi Kinerja Model

Sebagai evaluasi kuantitatif terhadap efisiensi algoritma bukan akurasi prediksi penelitian ini membandingkan jumlah kandidat yang dievaluasi Apriori dengan jumlah kombinasi pada pendekatan brute force (tanpa pruning):

Tabel 4.3.2. Evaluasi Kinerja Model

Pendekatan	Level 1	Level 2	Level 3	Total
Brute force (tanpa pruning)	120	7.140	280.840	288.100
Apriori manual (dengan pruning)	120	1.378	61	1.559
Pengurangan	—	—	—	99,46%

Hasil ini menjadi bukti kuantitatif keunggulan algoritma Apriori dibandingkan penelitian terdahulu pada BAB 2, yang umumnya hanya mengklaim efisiensi secara teoritis tanpa data pendukung. Pengurangan terbesar terjadi pada level 3 (dari 280.840 kemungkinan kombinasi murni menjadi hanya 61 kandidat), menunjukkan bahwa manfaat pruning semakin besar pada level itemset yang lebih tinggi — sesuatu yang konsisten dengan sifat eksponensial pertumbuhan kombinasi pada pendekatan brute force.

4.3.3. Pembahasan Temuan

Beberapa temuan dan implikasinya terhadap tujuan penelitian (BAB 1):

1. Pola pembelian dominan berbasis bahan masakan rule-rule dengan lift tertinggi secara konsisten melibatkan kombinasi bahan masakan (ground beef, spaghetti, olive oil, tomatoes), bukan produk acak. Temuan ini menjawab rumusan masalah ketiga (pola pembelian apa yang paling sering muncul) dan dapat dimanfaatkan pelaku ritel untuk strategi *bundling* produk masakan Italia.

2. Mineral water sebagai produk "jangkar" dengan support tertinggi (0,238) dan keterlibatan pada beberapa rule dengan confidence tinggi, produk ini layak ditempatkan di lokasi strategis karena dibeli lintas segmen pelanggan.
3. Pruning Apriori terbukti signifikan secara matematis maupun empiris verifikasi $C(53,2) = 1.378$ pada 4.2.1 dan pengurangan 99,46% kandidat pada 4.3.2 bersama-sama membuktikan bahwa implementasi manual ini bekerja sesuai teori BAB 2, sekaligus menunjukkan keunggulan kuantitatif yang jarang ditemukan pada penelitian sejenis.

Keterbatasan penelitian:

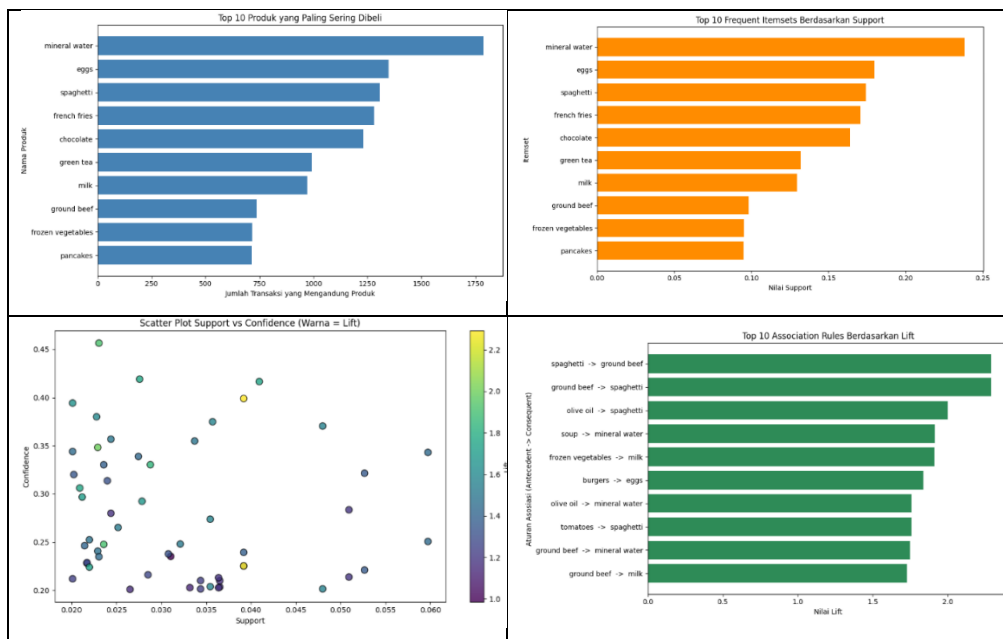
implementasi manual ini belum dioptimalkan menggunakan struktur data lanjutan seperti *hash tree*, sehingga kemungkinan masih lebih lambat dibandingkan pustaka teroptimasi seperti *mlxtend* pada dataset yang jauh lebih besar dari 7.501 transaksi. Nilai `min_support` dan `min_confidence` juga ditentukan berdasarkan studi literatur, bukan melalui pengujian sistematis beberapa kombinasi parameter. Selain itu, algoritma Apriori tidak memperhitungkan dimensi waktu, sehingga pola musiman tidak tertangkap (berbeda dengan pendekatan (Rana & Mondal, 2021) pada BAB 2.

Saran penelitian lanjutan: Membandingkan algoritma Apriori dengan FP-Growth pada dataset yang sama untuk membandingkan efisiensi waktu eksekusi secara langsung, serta menguji sensitivitas hasil terhadap beberapa kombinasi nilai `min_support/min_confidence`.

4.3.4. Hasil

Implementasi algoritma Apriori manual pada dataset Market Basket Optimisation (7.501 transaksi, 120 produk unik) dengan `min_support = 0,02` dan `min_confidence = 0,2` menghasilkan 103 frequent itemset dan 55 association rules, dengan rule terkuat `ground beef → spaghetti` (confidence 39,9%, lift 2,29). Efisiensi algoritma terbukti secara kuantitatif melalui pengurangan 99,46% kandidat dibanding pendekatan brute force. Hasil ini didukung oleh empat visualisasi dari notebook penelitian (grafik 10 produk terpopuler, grafik 10 frequent itemset, scatter plot support–confidence–lift, dan grafik 10 rules dengan lift tertinggi) yang akan disertakan sebagai gambar pada dokumen final.

Gambar 4.3.4 Hasil Implementasi



BAB 5

PENUTUP

5.1. Kesimpulan

Berdasarkan hasil implementasi dan eksperimen yang telah dilakukan, dapat disimpulkan beberapa hal berikut, yang masing-masing menjawab rumusan masalah pada BAB 1:

1. Algoritma Apriori berhasil diimplementasikan secara manual (tanpa pustaka data mining siap pakai) pada data transaksi Market Basket Optimisation, melalui tiga fungsi utama (`hitung_support()`, `apriori_manual()`, `buat_rules_manual()`) yang terverifikasi bekerja sesuai definisi teoritis — dibuktikan antara lain melalui kesesuaian jumlah kandidat level 2 (1.378) dengan hasil perhitungan kombinatorik $C(53,2)$
2. Association rules berhasil ditentukan berdasarkan nilai support, confidence, dan lift, dengan ambang batas `min_support = 0,02` dan `min_confidence = 0,2`, menghasilkan 103 frequent itemset dan 55 association rules.
3. Pola pembelian yang paling sering muncul didominasi oleh kombinasi bahan masakan, dengan rule terkuat `ground beef → spaghetti` (confidence 39,9%, lift 2,29), diikuti oleh pola serupa seperti `olive oil/tomatoes` terhadap spaghetti.
4. Algoritma Apriori terbukti secara kuantitatif lebih efisien dibandingkan pendekatan brute force, dengan pengurangan jumlah kandidat yang dievaluasi sebesar 99,46% pada dataset ini.
5. Nilai lift terbukti penting untuk menyaring hubungan antar item yang benar-benar bermakna ($\text{lift} > 1$), membedakannya dari hubungan yang tinggi confidence-nya hanya karena popularitas salah satu item.

5.2. Saran

Berdasarkan keterbatasan yang telah diuraikan pada BAB 4, beberapa saran untuk penelitian maupun pengembangan lebih lanjut:

1. Membandingkan algoritma Apriori dengan algoritma FP-Growth pada dataset yang sama, untuk mengukur secara langsung perbedaan waktu eksekusi dan efisiensi memori antara kedua pendekatan.
2. Menggunakan dataset transaksi yang lebih besar atau dari domain bisnis yang berbeda, untuk menguji apakah pola dan efisiensi yang ditemukan pada penelitian ini bersifat konsisten.

3. Melakukan pengujian sistematis terhadap beberapa kombinasi nilai `min_support` dan `min_confidence`, untuk melihat sensitivitas jumlah frequent itemset dan rules yang dihasilkan terhadap kedua parameter tersebut.
4. Mengoptimalkan implementasi manual dengan struktur data lanjutan (misalnya hash tree) agar performa algoritma lebih kompetitif dibandingkan pustaka siap pakai pada dataset berskala sangat besar.

DAFTAR PUSTAKA

- Agrawal, R., Imielinski, T., & Swami, A. (1993). *Mining Association Rules between Sets of Items in Large Databases*.
- Agrawal, R., & Srikant, R. (1994). *Fast Algorithms for Mining Association Rules*.
- Ana, S., Kurniawan, R., & Nazir, A. (2022). Pengklasteran Risiko Covid-19 Di Riau Menggunakan Teknik One Hot Encoding Dan Algoritma K-Means Clustering. *Jurnal Informasi Dan Komputer*, 10(1), 154–163. <https://doi.org/10.35959/jik.v10i1.291>
- Angelina M. T. I. Sambu Ua, Diandra Lestriani H, Elizabeth Sonia Kristanty Marpaung, Jesslyn Ong, Michelle Savinka, Putri Nurhaliza, & Rahmi Yulia Ningsih. (2023). Penggunaan Bahasa Pemrograman Python Dalam Analisis Faktor Penyebab Kanker Paru-Paru. *Jurnal Publikasi Teknik Informatika*, 2(2), 88–99. <https://doi.org/10.55606/jupti.v2i2.1742>
- Buulolo, E. (2020). *Data Mining Untuk Perguruan Tinggi*. Deepublish.
- d4rklucif3r. (n.d.). *Market Basket Optimisation*. Kaggle.
- Febrianto, M. D., & Supriyanto, A. (2022). Implementasi algoritma apriori untuk menentukan pola pembelian produk. *JURIKOM (Jurnal Ris. Komputer)*, 9(6), 2010.
- Karina, R. P., Lestanti, S., & Febrinita, F. (2022). Penerapan Algoritma Apriori Dalam Seleksi Penjurusan Calon Peserta Didik Baru Di Smak Diponegoro Blitar. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 6(2), 716–724. <https://doi.org/10.36040/jati.v6i2.5630>
- Nurhidayanti, D., & Kurniawati, I. (2022). Implementasi Algoritma Apriori Dalam Menemukan Association Rules Pada Persediaan Sparepart Motor. *Innovation in Research of Informatics (INNOVATICS)*, 4(2). <https://doi.org/10.37058/innovatics.v4i2.5300>
- Oktaviani, N. (2024). Implementasi Algoritma Apriori Untuk Analisis Pola Pembelian Konsumen Pada Toko Serba. *Jurnal Mahasiswa Teknik Informatika*, 8(3).
- Pravitasari, C., & Sutarsih, T. (2025). *Statistik E-Commerce 2024* (A. Setiawan, Ed.; Vol. 7). Badan Pusat Statistik Keuangan, Teknologi Informasi, dan Parawisata.
- Purwati, N., & Karnila, S. (2023a). Strategi Peningkatan Penjualan Produk Menggunakan Market Basket Analysis. *Jurnal Sistem Informasi Bisnis*, 13(2), 96–103. <https://doi.org/10.21456/vol13iss2pp96-103>
- Purwati, N., & Karnila, S. (2023b). Strategi Peningkatan Penjualan Produk Menggunakan Market Basket Analysis. *Jurnal Sistem Informasi Bisnis*, 13(2), 96–103. <https://doi.org/10.21456/vol13iss2pp96-103>
- Rana, S., & Mondal, M. N. I. (2021). *A Seasonal And Multilevel Association Based Approach For Market Basket Analysis in Retail Supermarket*.
- Syafira Rifania, V., Saniman, & Azlan. (2023). Penerapan Algoritma Apriori Dalam Mencari Pola Pembelian Konsumen. 2(2). <https://ojs.trigunadharma.ac.id/index.php/jsi>